



Instituto Tecnológico de Aeronáutica
Divisão de Engenharia Aeronáutica e Aeroespacial

Laboratório 3

Redes Neurais Convolucionais

Autores:

João Vitor Coelho Guimarães Lima

Professor:

Prof. Marcos Ricardo Omena de Albuquerque Maximo

2 de abril de 2026

1 Introdução

O presente relatório descreve o processo de implementação, treinamento e validação da arquitetura de rede neural convolucional **LeNet-5**, aplicada à classificação de dígitos manuscritos através do **dataset MNIST (Modified National Institute of Standards and Technology)**.

A LeNet-5, proposta originalmente por Yann LeCun, estabeleceu os fundamentos das **Redes Neurais Convolucionais (CNNs)** modernas, introduzindo o conceito de compartilhamento de pesos e subamostragem para o processamento de padrões espaciais. O conjunto de dados utilizado compreende uma base extensiva de imagens normalizadas em tons de cinza, servindo como padrão de referência para a avaliação de algoritmos de visão computacional.

O objetivo central desta atividade é reproduzir experimentalmente a arquitetura clássica, analisando a convergência do modelo e sua eficácia na predição de rótulos (**labels**) em relação às anotações originais do conjunto de teste.

2 Metodologia

A metodologia adotada neste laboratório consiste na implementação, no treinamento e na avaliação da rede convolucional **LeNet-5** aplicada ao problema de classificação de dígitos manuscritos do *dataset* MNIST. Todo o desenvolvimento foi realizado utilizando a *framework* **PyTorch**, em conformidade com as especificações descritas no enunciado do trabalho.

2.1 Conjunto de Dados

Foi utilizado o *dataset* **MNIST**, composto por imagens em tons de cinza de dígitos manuscritos (0 a 9). Como a arquitetura original da LeNet-5 espera entradas com dimensões $32 \times 32 \times 1$ e as imagens do MNIST possuem originalmente 28×28 *pixels*, foi aplicada uma transformação de *padding* para ajustar as imagens ao tamanho esperado pela rede. Adicionalmente, os *pixels* foram normalizados antes de serem fornecidos como entrada.


2.2 Arquitetura da Rede LeNet-5

A arquitetura implementada segue fielmente a descrição clássica da LeNet-5, conforme apresentado na Tabela 1. A rede é composta por sete camadas treináveis, alternando camadas convolucionais (**Conv2D**) e camadas de *pooling* por média (**AveragePooling2D**), seguidas por duas camadas totalmente conectadas (*Dense / Fully Connected*). A função de ativação utilizada nas camadas intermediárias é a **tangente hiperbólica (tanh)**, enquanto a camada de saída utiliza a função **softmax** para produzir uma distribuição de probabilidade sobre as 10 classes do problema.

Tabela 1: Arquitetura da LeNet-5.

Camada	Tipo	Nº Filtros	Saída	Kernel	Stride	Ativação
Entrada	Imagem	1	32×32	–	–	–
1	Conv2D	6	28×28	5×5	1	tanh
2	AveragePooling2D	6	14×14	2×2	2	–
3	Conv2D	16	10×10	5×5	1	tanh
4	AveragePooling2D	16	5×5	2×2	2	–
5	Conv2D	120	1×1	5×5	1	tanh
6	Dense (FC)	–	84	–	–	tanh
7	Dense (FC)	–	10	–	–	softmax

A entrada da rede é uma imagem com dimensões $(32, 32, 1)$, em que os valores representam, respectivamente, a largura, a altura e o número de canais de cor da imagem. O fluxo de dados pela rede pode ser resumido da seguinte forma: a imagem de entrada passa por sucessivas operações de convolução, que extraem características locais, intercaladas por operações de *average pooling*, responsáveis por reduzir a dimensionalidade espacial dos mapas de características. Após a quinta camada, o tensor resultante possui dimensão $1 \times 1 \times 120$ e é, então, encaminhado para as camadas totalmente conectadas, que realizam a classificação final.



Aplicado implicitamente pela CrossEntropyLoss durante o treino


■ Convolução ■ Average pooling ■ Totalmente conectada ■ Entrada / reshape

Figura 1: Arquitetura da rede LeNet-5 implementada.


3 Resultados

O desempenho do modelo LeNet-5 foi avaliado com base nas métricas de acurácia e perda ao longo do processo de treinamento, conforme detalhado a seguir:

A análise da Figura 2, que apresenta a relação entre a acurácia e o número de épocas, demonstra a evolução da precisão do modelo ao longo das 20 épocas de treinamento. A proximidade observada entre as curvas de treino, em azul, e de teste, em laranja, indica que o modelo está generalizando bem os dados apresentados. Nota-se que ambas as curvas atingem a estabilidade em patamares superiores a 0,975, o que representa um excelente resultado para esta arquitetura clássica. Complementarmente, a Figura 3 ilustra a minimização do erro ao longo do tempo através do gráfico de perda por época. Observa-se uma queda acentuada na função de perda durante as primeiras 5 épocas, o que caracteriza um aprendizado rápido da rede. O fato de a perda de teste não apresentar tendência de ascensão enquanto a perda de treinamento continua a decrescer confirma a ausência de *overfitting* significativo no processo.



(a) Evolução da Acurácia de Treino e Teste.



(b) Evolução da Função de Perda (Loss).

Figura 2: Curvas de aprendizado do modelo LeNet-5 durante 20 épocas.

A Figura 3 e a Figura 4 apresentam exemplos de predições realizadas pelo modelo LeNet-5 sobre o conjunto de teste MNIST. De forma geral, observa-se que a rede neural foi capaz de capturar adequadamente as características relevantes dos dígitos manuscritos, apresentando boa capacidade de generalização.


Na Figura 3, nota-se que as predições estão, em sua maioria, corretas e coerentes com os rótulos esperados. Mesmo em casos onde os dígitos apresentam variações de escrita, espessura ou leve distorção, o modelo mantém desempenho satisfatório. Isso indica que as camadas convolucionais foram eficazes na extração de padrões espaciais importantes.

Já na Figura 4, são apresentados exemplos adicionais do conjunto de teste. Observa-se que dígitos bem definidos, como “1”, “2” e “6”, são classificados com alta confiança. Em

contrapartida, alguns dígitos com traços menos convencionais ou ambíguos, como o “4” ou o “2” estilizado, podem representar maior dificuldade para o modelo, o que é esperado em problemas de reconhecimento de escrita manual.


Esses resultados sugerem que o modelo atingiu um bom nível de aprendizado, conseguindo equilibrar viés e variância de forma adequada. Eventuais erros podem ser atribuídos à variabilidade intrínseca do dataset MNIST, bem como à limitação da arquitetura em capturar padrões mais complexos sem aumento de profundidade ou técnicas adicionais de regularização.

De maneira geral, conclui-se que o desempenho do modelo é consistente com o esperado para a arquitetura LeNet-5, sendo capaz de realizar classificações precisas na maioria dos casos, com erros pontuais em exemplos mais desafiadores.



(a) Imagem 1112 (b) Imagem 1247 (c) Imagem 1901 (d) Imagem 6005 (e) Imagem 9811


Figura 3: Amostras de predição do modelo LeNet-5 sobre o conjunto de teste MNIST.



(a) Imagem 409

(b) Imagem 1824

(c) Imagem 3657



(d) Imagem 4012

(e) Imagem 4506

Figura 4: Exemplos de resultados obtidos nos testes com o dataset MNIST.

4 Conclusão

Neste trabalho, foi implementada e avaliada a arquitetura LeNet-5 aplicada ao problema de reconhecimento de dígitos manuscritos utilizando o dataset MNIST. Os resultados obtidos demonstraram que o modelo apresentou elevado desempenho de classificação, alcançando alta acurácia tanto no conjunto de treinamento quanto no conjunto de teste.

A análise das curvas de aprendizado evidenciou uma convergência rápida e estável ao longo das 20 épocas, com redução consistente da função de perda e sem indícios relevantes de sobreajuste. A proximidade entre as métricas de treino e teste confirma que a rede foi capaz de generalizar adequadamente os padrões presentes nos dados.

Além disso, a inspeção visual das amostras classificadas mostrou que o modelo reconhece corretamente a maior parte dos dígitos, mesmo diante de variações naturais de escrita. Os erros observados concentram-se principalmente em exemplos ambíguos ou com traços pouco convencionais, o que evidencia uma limitação inerente à variabilidade do próprio conjunto de dados.

Dessa forma, conclui-se que a arquitetura LeNet-5 permanece eficiente e robusta para tarefas clássicas de classificação de imagens simples, servindo como uma base sólida para o estudo de redes neurais convolucionais. Como continuidade do trabalho, pode-se explorar arquiteturas mais profundas, técnicas de regularização e estratégias de aumento de dados (*data augmentation*) com o objetivo de reduzir ainda mais os erros de classificação e ampliar a capacidade de generalização do modelo.